

MVP - Construção de um Pipeline de Dados na Nuvem

Gustavo Barbosa

Table of Contents

MVP — Construção de um Pipeline de Dados na Nuvem.....	1
1. Contexto de Negócios e Perguntas (Etapa 2 e 4.1)	2
2. Carga dos Dados (Etapa 4.2)	5
3. Modelagem e Catálogo de Dados (Etapa 4.3)	7
4. Pipeline de Dados (Etapa 4.4)	14
5. Qualidade de Dados (Etapa 4.5)	18
6. Análise de Dados (Etapa 4.5)	21
7. Autoavaliação.....	32
Como reproduzir	Erro! Indicador não definido.

MVP — Construção de um Pipeline de Dados na Nuvem

Curtailment (constrained-off) de geração eólica e fotovoltaica no Sistema Interligado Nacional

Aluno	Gustavo Barbosa
Disciplina	Engenharia de Dados — MVP: Pipeline de Dados na Nuvem
Plataforma	Databricks Free Edition
Repositório	https://github.com/Gusb1904/MVP2
Catálogo (Unity Catalog)	mvp_ons → schemas bronze, silver, gold
Fonte de dados	Portal de Dados Abertos do ONS — licença Creative Commons Atribuição (CC BY)

Construí este MVP inteiramente dentro do Databricks Free Edition, em seis notebooks encadeados que vão do download do arquivo bruto na origem até a resposta às perguntas de negócio. O pipeline segue a arquitetura medalhão: bronze (dado como veio), silver (dado limpo e tipado) e gold (modelo dimensional pronto para consumo), cada camada materializada como um schema do Unity Catalog com tabelas Delta gerenciadas.

Name	Type	Owner	Created at	Last updated at
00_config	Notebook	gutenberg@1904@gmail.com	Sep 13, 2020, 12:19 PM	Sep 13, 2020, 07:45 PM
01_ingestao_bronze	Notebook	gutenberg@1904@gmail.com	Sep 13, 2020, 12:19 PM	Sep 13, 2020, 07:46 PM
02_qualidade_bronze	Notebook	gutenberg@1904@gmail.com	Sep 13, 2020, 12:19 PM	Sep 13, 2020, 07:46 PM
03_transformacao_silver	Notebook	gutenberg@1904@gmail.com	Sep 13, 2020, 12:19 PM	Sep 13, 2020, 07:47 PM
04_modelagem_gold	Notebook	gutenberg@1904@gmail.com	Sep 13, 2020, 12:19 PM	Sep 13, 2020, 08:07 PM
05_analise_perguntas	Notebook	gutenberg@1904@gmail.com	Sep 13, 2020, 12:19 PM	Sep 13, 2020, 08:07 PM

Figura 1 — Os seis notebooks do pipeline no meu workspace Databricks.

Estrutura dos notebooks

Notebook	Papel
00_config	Parâmetros, catálogo de fontes, domínios de referência e funções utilitárias. Chamado pelos demais com %run ./00_config.
01_ingestao_bronze	Cria catálogo/schemas/Volume, baixa os CSVs do ONS e materializa as tabelas Bronze.
02_qualidade_bronze	Perfilagem de todos os atributos + 23 regras de qualidade sobre a Bronze.
03_transformacao_silver	Limpeza, tipagem, deduplicação, quarentena e derivações → camada Silver.
04_modelagem_gold	Modelo dimensional (dimensões + fatos) e gravação do catálogo de dados no Unity Catalog.
05_analise_perguntas	Consolidação da qualidade e resposta às nove perguntas de negócio.

1. Contexto de Negócios e Perguntas (Etapa 2 e 4.1)

1.1 O problema que eu quis resolver

O Nordeste brasileiro instalou muito mais capacidade eólica e fotovoltaica do que a rede consegue escoar e do que a carga local consegue absorver. Quando isso acontece, o ONS manda a usina reduzir a geração — é o **constrained-off** — e a energia renovável simplesmente deixa de existir: não é armazenada, não é exportada, não é faturada.

Eu quis **dimensionar esse desperdício, entender a causa dominante e identificar onde ele se concentra**. A motivação é prática: a decisão de investimento muda completamente conforme a resposta. Se o corte é gargalo de transmissão, a solução é linha nova. Se é excesso de oferta em hora de demanda baixa, a solução é armazenamento, resposta da demanda ou carga nova posicionada no horário certo. Sem dados, essa discussão vira opinião.

1.2 As perguntas que defini antes de tocar nos dados

Escrevi as nove perguntas abaixo **antes** de escolher a base, e as mantive intactas até o fim do trabalho — inclusive a que consegui responder apenas parcialmente.

- | # | Pergunta |
|----|--|
| P1 | Quanta energia eólica e fotovoltaica foi cortada por constrained-off entre março e agosto de 2026, e qual a taxa de corte sobre a geração de referência? |
| P2 | Eólica e fotovoltaica são afetadas na mesma proporção? |
| P3 | O corte é predominantemente por razão energética (excesso de oferta) ou por confiabilidade/rede? A origem é sistêmica ou local? |
| P4 | Como o corte evoluiu mês a mês? O problema está piorando? |
| P5 | Qual subsistema concentra o corte, e isso acompanha a penetração de geração intermitente? |
| P6 | Existe padrão horário do corte? Eólica e solar são cortadas nos mesmos horários? |
| P7 | O corte está concentrado em poucas usinas ou é difuso? |
| P8 | O corte energético ocorre nas horas de menor carga líquida e com reservatórios mais cheios? |
| P9 | Como evoluiu a penetração de eólica e solar na carga do SIN entre 2021 e 2026? |




Figura 2 — Problema e as nove perguntas registrados no notebook `05_analise_perguntas`.

1.3 Os dados brutos que escolhi

Todos os conjuntos vêm do **Portal de Dados Abertos do ONS** (dados.ons.org.br), publicados em CSV com separador ; e codificação UTF-8. Escolhi cinco conjuntos porque cada um responde a uma parte diferente das perguntas — os dois primeiros medem o corte, os demais dão o contexto necessário para explicá-lo.

Dataset (tabela Bronze)	O que é	Grão	Janela	Linhas na Bronze
<code>restricao_coff_eolica</code>	Restrição de operação por constrained-off de usinas eólicas	usina/conjunto × 30 min	mar–ago/2026	1.353.118
<code>restricao_coff_fotovoltaica</code>	Restrição de operação por constrained-off de usinas fotovoltaicas	usina/conjunto × 30 min	mar–ago/2026	696.372

Dataset (tabela Bronze)	O que é	Grão	Janela	Linhas na Bronze
	off de usinas fotovoltaicas			
balanco_energia_subsystema	Balanco de energia: geração por fonte, carga e intercâmbio	subsystema × hora	2021–2026	249.240
ear_diario_subsystema	Energia Armazenada (EAR) — nível dos reservatórios	subsystema × dia	2021–2026	8.308
capacidade_geracao	Cadastro de capacidade instalada por unidade geradora	unidade geradora	cadastro atual	5.675

Estrutura dos arquivos de restrição (os mais importantes do trabalho), conforme o dicionário oficial “*Restrição de Operação por Constrained-off em Usinas Eólicas/Fotovoltaicas*”:

id_subsystema, nom_subsystema, id_estado, nom_estado, nom_usina, id_ons, ceg, din_instante, val_geracao (geração verificada), val_geracaolimitada, val_disponibilidade, val_geracaoreferencia, val_geracaoreferenciafinal, val_geracaonaorealizadaapurada (**GNRa — o corte apurado**), cod_razaorestricao, cod_origemrestricao, dsc_restricao, num_minutos_restricao, num_minutos_rel, num_minutos_cnf, num_minutos_ene, id_pontoconexao, nom_pontoconexao, nom_agenteoperador.

A métrica central do MVP é val_geracaonaorealizadaapurada: a energia que a usina deixou de gerar por ordem do operador, em MWmed no intervalo de 30 minutos. É o número que eu converto para MWh e agrego em todas as análises.

Estrutura dos demais arquivos:

- balanco_energia_subsystema: id_subsystema, nom_subsystema, din_instante, val_gerhidraulica, val_gertermica, val_gereolica, val_gersolar, val_carga, val_intercambio.
- ear_diario_subsystema: id_subsystema, nom_subsystema, ear_data, ear_max_subsystema, ear_verif_subsystema_mwmes, ear_verif_subsystema_percentual.

- `capacidade_geracao: id_subsistema, id_estado, nom_estado, nom_tipousina, nom_usina, ceg, nom_combustivel, nom_agente proprietario, cod_equipamento, dat_entrada operacao, dat_desativacao, val_potencia efetiva.`

Decisão de escopo (duas janelas temporais). Usei série longa (2021–2026) para balanço e reservatórios, porque são arquivos anuais pequenos e permitem enxergar a tendência de seis anos que a P9 pede. Para os dados de restrição usei uma janela de seis meses (mar–ago/2026), porque os arquivos mensais são muito maiores (~40 MB cada, granularidade de 30 minutos por usina) e seis meses já entregam 2 milhões de registros — massa suficiente para as perguntas, mantendo o pipeline dentro dos limites da Free Edition.

1.4 Licença dos dados

Os dados do Portal de Dados Abertos do ONS são publicados sob **Creative Commons Atribuição (CC BY)**. A licença permite uso, redistribuição e adaptação, inclusive para fins comerciais, desde que a fonte seja atribuída. Registre a licença como constante no próprio código (`LICENCA_FONTE`, no notebook `00_config`) e no comentário de cada tabela Bronze gravado no Unity Catalog, de modo que ela viaje junto com o dado e não só com este documento. Atribuição: *Operador Nacional do Sistema Elétrico (ONS) — Portal de Dados Abertos*, <https://dados.ons.org.br>.

Não redistribuo os dados neste repositório: o pipeline baixa os arquivos da URL pública de origem a cada execução, o que também mantém a rastreabilidade.

2. Carga dos Dados (Etapa 4.2)

2.1 Como fiz

A coleta é 100% programática, executada de dentro do Databricks — não baixei nada para a minha máquina. O notebook `01_ingestao_bronze` faz, nesta ordem:

1. **Cria a estrutura do Lakehouse:** catálogo `mvp_ons`, schemas `bronze/silver/gold` e o Volume `mvp_ons.bronze.raw_ons` (Unity Catalog Volumes), com `COMMENT` em cada objeto.
2. **Baixa os 25 arquivos CSV** direto do bucket público do ONS (`ons-aws-prod-opendata.s3.amazonaws.com`) para dentro do Volume, com a função `baixar()`: streaming em blocos de 1 MB, timeout de 300 s, até 3 tentativas com backoff, e **idempotência** — se o arquivo já está no Volume, não baixa de novo.
3. **Grava o manifesto de ingestão** na tabela `bronze._manifesto_ingestao`: uma linha por arquivo, com URL de origem, caminho no Volume, tamanho em bytes, status e timestamp. Essa tabela é a evidência de linhagem entre a fonte pública e as tabelas Bronze, e o notebook falha explicitamente (`assert`) se qualquer download não tiver dado certo.

4. **Materializa as tabelas Bronze** lendo os CSVs **sem inferência de tipo** (`inferSchema=false`): tudo entra como `STRING`, exatamente como veio. A única coisa que acrescento são três metadados de controle — `_ingest_ts`, `_source_file` (via `_metadata.file_path`) e `_source_dataset`.

A regra que segui na Bronze foi rígida: **nenhuma regra de negócio**. Separador `;` e encoding `UTF-8` são características do arquivo, não transformação. Se o CSV chegou torto, ele fica torto na Bronze — o tratamento acontece na Silver, e isso é o que me permite voltar ao dado original quando alguma conta não fecha.

```
def ler_csv_bruto(caminho: str):  
    return (spark.read  
            .option("header", "true").option("sep", ";")  
            .option("encoding", "UTF-8").option("inferSchema", "false")  
            .option("mode", "PERMISSIVE").csv(caminho))  
  
def carimbar(df, dataset: str):  
    return (df.withColumn("_ingest_ts", F.current_timestamp())  
            .withColumn("_source_file", F.col("_metadata.file_path"))  
            .withColumn("_source_dataset", F.lit(dataset)))
```

Script: `notebooks_pipeline/01_ingestao_bronze` (parâmetros e funções em `00_config`).




Figura 3 — Os CSVs do ONS dentro do Volume `mvp_ons.bronze.raw_ons` no Unity Catalog.

```
7/home2/spark-4a9ab5e8-0dae-4841-b9f3-2e71.pykernel176/command=8429597912082004=412411075213: DeprecationWarning:
"ingest_ts": datetime.utcnow().isoformat(timespec="seconds"),
balanco_energia_substema      BALANCO_ENERGIA_SUBSISTEMA_2021.csv      5.1 MB  ja_existia
balanco_energia_substema      BALANCO_ENERGIA_SUBSISTEMA_2022.csv      5.1 MB  ja_existia
balanco_energia_substema      BALANCO_ENERGIA_SUBSISTEMA_2023.csv      4.5 MB  ja_existia
balanco_energia_substema      BALANCO_ENERGIA_SUBSISTEMA_2024.csv      4.6 MB  ja_existia
balanco_energia_substema      BALANCO_ENERGIA_SUBSISTEMA_2025.csv      4.1 MB  ja_existia
balanco_energia_substema      BALANCO_ENERGIA_SUBSISTEMA_2026.csv      3.2 MB  ja_existia
ear_diario_substema           EAR_DIARIO_SUBSISTEMA_2021.csv           0.1 MB  ja_existia
ear_diario_substema           EAR_DIARIO_SUBSISTEMA_2022.csv           0.1 MB  ja_existia
ear_diario_substema           EAR_DIARIO_SUBSISTEMA_2023.csv           0.1 MB  ja_existia
ear_diario_substema           EAR_DIARIO_SUBSISTEMA_2024.csv           0.1 MB  ja_existia
ear_diario_substema           EAR_DIARIO_SUBSISTEMA_2025.csv           0.1 MB  ja_existia
ear_diario_substema           EAR_DIARIO_SUBSISTEMA_2026.csv           0.0 MB  ja_existia
capacidade_geracao            CAPACIDADE_GERACAO.csv                  1.3 MB  ja_existia
restricao_coff_eolica          RESTRICAO_COFF_EOLICA_2026_03.csv        39.7 MB  ja_existia
restricao_coff_eolica          RESTRICAO_COFF_EOLICA_2026_04.csv        39.4 MB  ja_existia
restricao_coff_eolica          RESTRICAO_COFF_EOLICA_2026_05.csv        42.4 MB  ja_existia
restricao_coff_eolica          RESTRICAO_COFF_EOLICA_2026_06.csv        41.2 MB  ja_existia
restricao_coff_eolica          RESTRICAO_COFF_EOLICA_2026_07.csv        44.3 MB  ja_existia
restricao_coff_eolica          RESTRICAO_COFF_EOLICA_2026_08.csv        46.8 MB  ja_existia
restricao_coff_fotovoltaica     RESTRICAO_COFF_FOTOVOLTAICA_2026_03.csv  19.4 MB  ja_existia
restricao_coff_fotovoltaica     RESTRICAO_COFF_FOTOVOLTAICA_2026_04.csv  19.1 MB  ja_existia
restricao_coff_fotovoltaica     RESTRICAO_COFF_FOTOVOLTAICA_2026_05.csv  19.8 MB  ja_existia
restricao_coff_fotovoltaica     RESTRICAO_COFF_FOTOVOLTAICA_2026_06.csv  19.2 MB  ja_existia
restricao_coff_fotovoltaica     RESTRICAO_COFF_FOTOVOLTAICA_2026_07.csv  20.3 MB  ja_existia
restricao_coff_fotovoltaica     RESTRICAO_COFF_FOTOVOLTAICA_2026_08.csv  21.1 MB  ja_existia

OK - 25 arquivos disponiveis no Volume (401.2 MB no total).
```

Figura 4 — Resultado da ingestão: manifesto por dataset e contagem de linhas/colunas de cada tabela Bronze.

2.2 Por que não usei upload manual

Poderia ter arrastado os CSVs para o Databricks pela interface, mas isso quebraria a reprodutibilidade: em novembro, com dois meses novos publicados, bastaria eu alterar JANELA_RESTRICAO no 00_config e rodar o notebook 01 de novo. O manifesto registra o que entrou, e a idempotência evita baixar o que já está lá.

3. Modelagem e Catálogo de Dados (Etapa 4.3)

3.1 O modelo que escolhi

Modelei a camada Gold como um **esquema estrela em constelação** (*fact constellation*): quatro tabelas fato compartilhando dimensões conformes. Escolhi estrela — e não flat nem snowflake — porque o problema tem um fato central óbvio (o corte, medido por usina e por hora) cercado de dimensões naturais (tempo, hora do dia, subsistema, fonte, usina), e porque quase todas as perguntas são recortes do mesmo fato por dimensões diferentes. Um modelo flat obrigaria a repetir atributos de usina em milhões de linhas; o snowflake normalizaria dimensões que têm dezenas de linhas, complicando as consultas sem ganho real.

Tabela Gold	Tipo	Grão
dim_data	Dimensão conforme	dia
dim_hora	Dimensão conforme	hora do dia (24 linhas)
dim_subsistema	Dimensão conforme	subsistema elétrico (5 linhas)
dim_fonte_geracao	Dimensão conforme	fonte de geração (4 linhas)
dim_usina	Dimensão	usina/conjunto eólico ou fotovoltaico (236 linhas)
fato_restricao_horaria	Fato central	usina × hora
fato_geracao_horaria	Fato	subsistema × hora × fonte
fato_balanco_horario	Fato	subsistema × hora
fato_reservatorio_diario	Fato	subsistema × dia
qualidade_perfil_atributos	Qualidade	tabela × coluna da Bronze
qualidade_regras	Qualidade	regra de qualidade

Duas decisões de modelagem que valem o registro:

- **dim_subsistema tem uma trava contra dupla contagem.** O arquivo do ONS traz a linha agregada SIN misturada com os subsistemas. Se eu somasse tudo, dobraria a energia. Marquei a linha com `eh_agregado = true` e excluí o SIN explicitamente dos fatos por subsistema.
- **dim_usina precisou de um join por nome normalizado.** As duas fontes do ONS (restrição e cadastro de capacidade) não compartilham chave: uma usa `id_ons`, a outra `cod Equipamento/ceg`, e o `ceg` está ausente em ~93% das linhas de restrição. Normalizei o nome da usina (maiúsculas, sem acento, sem pontuação, sem o prefixo CONJ./UFV/EOL/UEE) e fiz o join por essa chave. Como o match não é garantido, criei a flag `tem_cadastro_capacidade` para que ausência de correspondência nunca seja lida como potência zero.

3.2 Catálogo de dados

Documentei o modelo **no próprio Unity Catalog** — não em um arquivo à parte — usando `COMMENT ON CATALOG/SCHEMA/TABLE` e `ALTER TABLE ... ALTER COLUMN ... COMMENT`. Cada comentário de coluna traz descrição, tipo, domínio de valores e, quando aplicável, a linhagem (de qual campo de origem ela veio e que transformação sofreu). O catálogo fica assim disponível para qualquer pessoa que abra o Catalog Explorer, e o Databricks ainda gera o diagrama de linhagem automaticamente.



Figura 5 — Catálogo mvp_ons e os três schemas (bronze, silver, gold) no Catalog Explorer.





Figura 6 — As onze tabelas persistidas no schema gold.






Figura 8 — Linhagem automática: bronze → silver → gold para `fato_restricao_horaria`.

3.2.1 `gold.fato_restricao_horaria` — `fato central`

Grão: usina × hora. Mede o curtailment (constrained-off) de geração eólica e fotovoltaica entre março e agosto de 2026. Linhagem:

`silver.restricao_coff_usina` agregada de intervalos de 30 minutos para hora; razão e origem da restrição resolvidas pelo intervalo de maior corte dentro da hora. **1.023.624 linhas.**

Campo	Tipo	Descrição / domínio
<code>sk_data</code>	INT	FK para <code>dim_data</code> (AAAAMMDD).
<code>sk_hora</code>	INT	FK para <code>dim_hora</code> . 0 a 23.
<code>sk_usina</code>	INT	FK para <code>dim_usina</code> .
<code>sk_subsistema</code>	INT	FK para <code>dim_subsistema</code> .
<code>sk_fonte</code>	INT	FK para <code>dim_fonte_geracao</code> . Somente EOL e SOL ocorrem neste fato.
<code>din_instante</code>	TIMESTAMP	Instante da hora cheia a que a linha se refere.
<code>corte_mwh</code>	DOUBLE	Medida aditiva. Energia não gerada por restrição, em MWh. Origem: <code>val_geracaonaorealizadaapurada</code> (GNRa), somado nos dois intervalos de 30 min e convertido de MWmed para MWh pelo fator 0,5 h. Faixa: ≥ 0 .
<code>geracao_mwh</code>	DOUBLE	Medida aditiva. Energia efetivamente gerada e verificada na hora, em MWh. Faixa: ≥ 0 .
<code>geracao_referencia_mwh</code>	DOUBLE	Medida aditiva. Energia que a usina teria gerado sem restrição (geração de referência do ONS, RO-AO.BR.13). Denominador da taxa de corte.

Campo	Tipo	Descrição / domínio
intervalos_com_restricao	INT	Quantos dos intervalos de 30 min da hora tiveram restrição. 0 a 2.
intervalos_no_periodo	INT	Quantos intervalos de 30 min existem para a usina naquela hora. Tipicamente 2.
cod_razao_restricao	STRING	Razão predominante na hora. Domínio: REL, CNF, ENE, PAR, NULL (sem restrição).
dsc_razao_restricao	STRING	Domínio: <i>Indisponibilidade externa (elétrica), Atendimento a requisitos de confiabilidade, Razão energética (excesso de oferta), Restrição indicada no parecer de acesso, Sem restrição.</i>
cod_origem_restricao	STRING	Domínio: LOC, SIS, NULL.
dsc_origem_restricao	STRING	Domínio: <i>Local, Sistêmica, Sem restrição.</i>
houve_restricao_na_hora	BOOLEAN	true quando ao menos um intervalo da hora teve restrição.
taxa_corte_pct	DOUBLE	Medida não aditiva (razão). $\text{corte_mwh} / \text{geracao_referencia_mwh} \times 100$. Em agregações deve ser recalculada como $\text{sum}(\text{corte}) / \text{sum}(\text{referencia})$, nunca como média desta coluna.

3.2.2 gold.dim_usina

Usina/conjunto eólico ou fotovoltaico sujeito a constrained-off. Linhagem: silver.restricao_coff_usina enriquecida com silver.capacidade_instalada_ug por join pelo nome normalizado. **236 linhas** (153 eólicas, 83 fotovoltaicas).

Campo	Tipo	Descrição / domínio
sk_usina	INT	Chave substituta sequencial.
id_ons	STRING	Identificador da usina/conjunto no ONS. Chave natural.
nom_usina	STRING	Nome como publicado pelo ONS.
cod_fonte / nom_fonte	STRING	EOL/Eólica, SOL/Fotovoltaica.
id_estado / nom_estado	STRING	UF (2 letras maiúsculas) e nome por extenso.
id_subsistema	STRING	Domínio: N, NE, S, SE.
potencia_instalada_mw	DOUBLE	Soma da potência efetiva das unidades geradoras ativas. NULL quando não houve correspondência no cadastro.

Campo	Tipo	Descrição / domínio
qtd_unidades_geradoras	INT	Unidades geradoras somadas na potência instalada.
dat_entrada_operacao	DATE	Entrada em operação da unidade mais antiga.
disponibilidade_maxima_mwmed	DOUBLE	Maior disponibilidade eletromecânica observada; proxy de porte quando não há cadastro.
tem_cadastro_capacidade	BOOLEAN	true quando o enriquecimento teve correspondência. Evita ler ausência de match como potência zero.
primeiro_registro / ultimo_registro	TIMESTAMP	Janela em que a usina aparece nos dados de restrição.

3.2.3 gold.dim_subsistema

Campo	Tipo	Descrição / domínio
sk_subsistema	INT	Chave substituta. 1 a 5.
id_subsistema	STRING	Domínio: N, NE, S, SE, SIN.
nom_subsistema	STRING	Norte, Nordeste, Sul, Sudeste/Centro-Oeste, Sistema Interligado Nacional.
nom_subsistema_ons	STRING	Nome exatamente como publicado pelo ONS (rastreadabilidade com a origem).
estados	STRING	UFs atendidas pelo subsistema.
eh_agregado	BOOLEAN	true apenas para SIN. Trava contra dupla contagem.

3.2.4 gold.dim_fonte_geracao

Campo	Tipo	Descrição / domínio
sk_fonte	INT	Chave substituta. 1 a 4.
cod_fonte	STRING	HID, TER, EOL, SOL.
nom_fonte	STRING	Hidráulica, Térmica, Eólica, Fotovoltaica.
eh_renovavel	BOOLEAN	true para hidráulica, eólica e fotovoltaica.
eh_despachavel	BOOLEAN	true quando a geração pode ser programada (hidráulica, térmica).
eh_intermitente	BOOLEAN	true para eólica e fotovoltaica — as fontes sujeitas a constrained-off.
coluna_origem	STRING	Linhagem: coluna do arquivo de balanço do ONS da qual a fonte foi despivotada.

3.2.5 gold.dim_data e gold.dim_hora

dim_data (grão dia, cobrindo o intervalo observado nos fatos): sk_data (AAAAMMDD), data (DATE), ano, mes, nom_mes (Janeiro–Dezembro), dia, ano_mes (AAAA-MM), trimestre (1–4), num_dia_semana (1=domingo a 7=sábado), nom_dia_semana, eh_fim_semana (BOOLEAN), dia_do_ano (1–366), estacao_ano (Verão, Outono, Inverno, Primavera — hemisfério sul).

dim_hora (24 linhas): sk_hora (0–23), hora, hora_rotulo ('00:00'–'23:00'), periodo_dia (Madrugada 0–5, Manhã 6–11, Tarde 12–17, Noite 18–23), eh_horario_ponta (true entre 18h e 21h), eh_janela_solar (true entre 7h e 18h).

3.2.6 gold.fato_balanco_horario

Grão: subsistema × hora. Linhagem: silver.balanco_subsistema_horario, excluindo a linha agregada SIN. Fornece a carga líquida, indicador usado para explicar o corte por razão energética.

Campo	Tipo	Descrição
sk_data, sk_hora, sk_subsistema	INT	FKs. sk_subsistema nunca é SIN.
din_instante	TIMESTAMP	Hora cheia.
carga_mwmed	DOUBLE	Medida aditiva. Carga do subsistema na hora.
ger_total_mwmed	DOUBLE	Medida aditiva. Soma hidráulica + térmica + eólica + solar.
ger_intermitente_mwmed	DOUBLE	Medida aditiva. Soma eólica + fotovoltaica.
carga_liquida_mwmed	DOUBLE	Medida aditiva. Carga – geração intermitente. Demanda a ser atendida por fontes despacháveis; valores baixos indicam excesso de oferta renovável.
intercambio_mwmed	DOUBLE	Medida aditiva. Positivo = exportação, negativo = importação.
pct_intermitente_sobre_carga	DOUBLE	Medida não aditiva (razão). Penetração de eólica+solar sobre a carga, em %.
carga_liquida_negativa	BOOLEAN	true quando a geração intermitente sozinha supera a carga do subsistema.

3.2.7 gold.fato_geracao_horaria e gold.fato_reservatorio_diario

fato_geracao_horaria (subsistema × hora × fonte; linhagem: silver.balanco_subsistema_horario **despivotado** — as quatro colunas de geração

viram linhas, excluindo SIN): sk_data, sk_hora, sk_subsistema, sk_fonte, din_instante, geracao_mwmed (DOUBLE, ≥ 0), geracao_mwh (medida aditiva; no grão horário equivale numericamente a MWmed).

fato_reservatorio_diario (subsistema $\times$ dia; linhagem: silver.ear_subsistema_diario): sk_data, sk_subsistema (inclui SIN), dat_referencia (DATE), ear_verificada_mwmes (DOUBLE ≥ 0), ear_maxima_mwmes (DOUBLE > 0), ear_percentual (DOUBLE 0–100), faixa_armazenamento (Baixo $< 30\%$ / Médio-baixo 30–50% / Médio-alto 50–70% / Alto $\geq 70\%$).

3.2.8 Camada Silver (tabelas intermediárias documentadas)

Tabela	Descrição e linhagem
silver.restricao_coff_usina	Restrição por constrained-off, usina $\times$ 30 min (mar–ago/2026). Tabela central. União de bronze.restricao_coff_eolica + bronze.restricao_coff_fotovoltaica, com quarentena de linhas malformadas, tipagem, deduplicação por id_ons+din_instante, conversão MWmed $\rightarrow$ MWh (fator 0,5 h) e tradução dos códigos de razão/origem. 2.047.248 linhas.
silver.restricao_coff_rejeitados	Quarentena. Registros descartados por deslocamento de colunas no CSV de origem. Preservados para auditoria e reprocessamento. 2.242 linhas.
silver.balanco_subsistema_horario	Balanço por subsistema, horário, limpo e tipado (2021–2026). Inclui a linha SIN marcada por eh_agregado. Derivações: geração total, geração intermitente, carga líquida, penetração.
silver.ear_subsistema_diario	EAR por subsistema, diária (2021–2026). Tipagem, deduplicação, validação do percentual entre 0 e 100.
silver.capacidade_instalada_ug	Cadastro de unidades geradoras com potência efetiva. Tipagem de datas/potência, descarte de potência ≤ 0 , deduplicação por cod_equipamento, derivação de esta_ativa.


4. Pipeline de Dados (Etapa 4.4)

4.1 Como organizei

Ramifiquei em um notebook por etapa do pipeline, mais um notebook de configuração compartilhado. Não fiz tudo num notebook só por três motivos: cada

etapa tem um custo de execução muito diferente (a ingestão baixa 25 arquivos, a Silver processa 2 milhões de linhas), eu queria poder reexecutar a modelagem sem rebaixar tudo, e a separação torna o notebook 05 legível como um documento de análise em vez de um paredão de código.

O `00_config` é chamado por todos os demais com `%run ./00_config`, de modo que constantes (catálogo, janelas, catálogo de fontes, domínios) e funções utilitárias (baixar, ler_csv_bruto, carimbar, para_null, para_decimal, salvar, comentar_tabela, comentar_colunas) passam a existir no namespace do notebook chamador. Isso garante que a regra de conversão decimal, por exemplo, seja exatamente a mesma em todas as tabelas.



Tudo é gravado como **tabela Delta gerenciada** no Unity Catalog pela mesma função:

```

def salvar(df, tabela: str, particao: str = None):
    w =
df.write.format("delta").mode("overwrite").option("overwriteSchema",
"true")
    if particao:
        w = w.partitionBy(particao)
        w.saveAsTable(tabela)
    return spark.table(tabela).count()

```

Particionei `silver.restricao_coff_usina` e `gold.fato_restricao_horaria` por `cod_fonte/sk_fonte`, porque quase toda pergunta separa eólica de fotovoltaica e esse é o filtro mais frequente.

4.2 Transformações Bronze → Silver, e por que cada uma

#	Transformação	Por quê	Impacto
1	<code>trim()</code> em todas as colunas de identificação	No arquivo de 2026 a sigla do subsistema vem com espaços à direita ('N ')	Sem isso, 24.096 linhas quebrariam o join com <code>dim_subsistema</code>
2	Sentinelas (' ', -, --, NA, N/A, null, None, nan) → NULL	O ONS usa vários marcadores textuais de	Ausência passa a ser detectável por IS NULL em vez de ficar escondida em string

#	Transformação	Por quê	Impacto
		“sem informação”	
3	Conversão decimal tolerante a dois formatos (1234.56 e 1.234,56)	Os arquivos misturam ponto e vírgula decimal	Evita NULL silencioso em milhares de valores numéricos
4	Tipagem: <code>to_timestamp</code> , <code>to_date</code> , <code>cast("double")</code> , <code>cast("int")</code>	Bronze é 100% STRING por regra	Permite ordenação, agregação e janelas temporais corretas
5	Quarentena de linhas com <code>id_estado</code> fora do padrão de UF	Aspas duplas não escapadas em <code>dsc_restricao</code> o deslocam os campos à direita no CSV	2.242 linhas isoladas em <code>silver.restricao_coff_rejeitados</code> (0,109% do lido) em vez de contaminarem os fatos
6	<code>dropDuplicates</code> pela chave natural de cada tabela	O ONS reprocessa arquivos mensalmente	2.187 duplicatas removidas nos arquivos de restrição
7	UNION de eólica + fotovoltaica com coluna <code>cod_fonte</code>	As duas fontes têm o mesmo layout e o mesmo significado de negócio	Uma tabela central em vez de duas, sem perder a distinção por fonte
8	<code>corte_apurado</code> NULL → 0.0 e <code>flag_houve_restricao</code>	Intervalo sem restrição não tem corte apurado: o NULL significa <i>zero corte</i> , não <i>dado faltante</i>	Corrige o erro grave de imputar média em ~60% das linhas
9	Conversão MWmed → MWh com fator 0,5 h	O arquivo de restrição é de 30 minutos e a métrica publicada é potência média	Permite somar energia corretamente em qualquer nível de agregação
10	Tradução de <code>cod_razaorestricao/cod_origemrestricao</code> para descrição	Os códigos REL/CNF/ENE/PAR e	Torna as análises legíveis sem consultar o dicionário

#	Transformação	Por quê	Impacto
		LOC/SIS não são autoexplicativos	
1	Derivações: ger_total,	São os	Cálculo feito uma vez, no
1	ger_intermitente, carga_liquida, pct_intermitente, esta_ativa	indicadores que as perguntas P5, P8 e P9 exigem	lugar certo

4.3 Transformações Silver → Gold

#	Transformação	Por quê
1	Agregação de 30 min → hora em fato_restricao_horaria	Alinha o grão do fato de restrição com o grão horário do balanço, tornando os dois comparáveis; reduz de 2,05 M para 1,02 M linhas
2	Razão/origem da hora resolvidas por row_number() sobre o intervalo de maior corte	Os dois intervalos de 30 min podem ter razões diferentes; escolher a do maior corte é a atribuição mais defensável
3	Join de id_ons, id_subsistema, cod_fonte com as dimensões para obter as chaves substitutas	Isola o fato das chaves naturais da origem
4	Despivotamento das 4 colunas de geração do balanço em linhas (fato_geracao_horaria)	Transforma “uma coluna por fonte” em “uma linha por fonte”, que é o formato que a dim_fonte_geracao exige
5	Exclusão explícita da linha SIN nos fatos por subsistema	Evita dobrar a energia somando o agregado junto com as partes
6	Enriquecimento de dim_usina com capacidade instalada por nome normalizado	As duas fontes do ONS não têm chave comum
7	COMMENT em catálogo, schemas, tabelas e colunas	O catálogo de dados é entregue no Unity Catalog, não em documento à parte

Exemplo concreto, no meu texto: *“Fiz um JOIN entre a tabela de restrição por usina e o cadastro de capacidade instalada pelo nome normalizado da usina, porque as duas fontes do ONS não compartilham chave, para enriquecer cada usina com potência instalada e número de unidades geradoras — e marquei com tem_cadastro_capacidade as que não deram match, para que ausência de correspondência não seja lida como potência zero.”*

4.4 Evidência de persistência




Figura 9 — Tabelas da camada Silver gravadas no Unity Catalog, com a contagem de linhas e o volume em quarentena.




Figura 10 — `SHOW TABLES IN.mvp_ons.gold`: as onze tabelas persistidas, e a checagem de integridade referencial (zero órfãos em todas as relações fato→dimensão).

Scripts: 01_ingestao_bronze, 02_qualidade_bronze, 03_transformacao_silver, 04_modelagem_gold, 05_analise_perguntas.

5. Qualidade de Dados (Etapa 4.5)

Fiz a verificação de qualidade **sobre a camada Bronze**, antes de qualquer transformação, em duas frentes: uma perfilagem automática de todos os atributos e um conjunto de 23 regras nomeadas cobrindo as cinco dimensões pedidas (completude, consistência, unicidade, acurácia e outliers). Os dois resultados foram **materializados como tabelas** (gold.qualidade_perfil_atributos e gold.qualidade_regras), de modo que a verificação é parte do pipeline e não um comentário no notebook.

1.1 Perfil de completude dos atributos de origem

```

SELECT tabela, coluna, linhas_totais, qtd_nulos, qtd_senhas, pct_acumte, qtd_valores_distintos
FROM wms_gold.qualicon_perfil_atributos
ORDER BY pct_acumte DESC, tabela, coluna;

```

Tabela	Coluna	linhas_totais	qtd_nulos	qtd_senhas	1.2 pct_acumte	qtd_valores_distintos
restricao_coff_fotovoltaica	val_geraconferencial	696372	683134	0	98.3902	10496
restricao_coff_eolica	val_geraconferencial	1353118	1316142	0	97.2673	30639
restricao_coff_fotovoltaica	org	696372	0	660624	94.8665	35
restricao_coff_eolica	org	1353118	12	1254144	92.4864	43
capacidade_geracon	est_instalacao	3475	4012	0	82.4394	74
restricao_coff_fotovoltaica	num_minutos_cof	696372	484800	0	69.616	31
restricao_coff_fotovoltaica	num_minutos_ene	696372	484800	0	69.616	31
restricao_coff_fotovoltaica	num_minutos_restricao	696372	484800	0	69.616	31
restricao_coff_fotovoltaica	num_minutos_restricao	696372	484800	0	69.616	30
restricao_coff_fotovoltaica	val_geraconvernalizacaoapara...	696372	484800	0	69.616	142062
restricao_coff_fotovoltaica	cod_origemrestricao	696372	484380	0	69.5377	2
restricao_coff_fotovoltaica	cod_restricao	696372	484380	0	69.5377	3
restricao_coff_fotovoltaica	dtc_restricao	696372	484380	0	69.5377	162
restricao_coff_fotovoltaica	val_geraconiniciada	696372	484380	0	69.5377	38277
restricao_coff_eolica	num_minutos_cof	1353118	808714	0	59.7667	32

81 rows 45.22% runtime

Figura 11 — Perfil de completude e cardinalidade dos 81 atributos das cinco tabelas gold.

1.2 Resultado das regras de qualidade

```

SELECT dimensao, tabela, regra, qtd_violacoes, status, tratamento
FROM wms_gold.qualidade_regras
ORDER BY (status = "ALERJA") DESC, dimensao, qtd_violacoes DESC;

```

dimensao	tabela	regra	qtd_violacoes	status	tratamento
Acuracia	restricao_coff_eolica	num_minutos_restricao fora da faixa 0-30 (intervalo de 30 min)	15	ALERJA	Confirma que o grão do arquivo é menor de 30 minutos — prémissa da conversão MinMax — Min (valor 0.5 %)
Acuracia	restricao_coff_eolica	val_geraconvernalizacaoapara...	5	ALERJA	Valor regular seria convertido para NULL na Silver
Acuracia	restricao_coff_eolica	cont_apurado maior que a geracao de referencia (impossivel)	4	ALERJA	Coefficiente interno do cálculo da CNG (GMA) = referência — verificado, violação unilateral erro de origem
Completude	restricao_coff_eolica	val_geraconvernalizacaoapara...	808714	ALERJA	Intervalo sem restrição não tem corte apurado e NULL é semanticamente "sem corte". Na Silver viria 0.0 em corte_moment e houve re...
Completude	restricao_coff_eolica	cod_restricaoacumte	806904	ALERJA	Mesmo caso sem restrição no intervalo, não há razão. Mantido NULL e rotulado como "sem restrição" na Silver
Completude	capacidade_geracon	dat_desativacao acumte	4692	ALERJA	Auditoria esperada e informativa: unidade ainda em operação. Na Silver deriva a flag esta_ativa
Consistencia	balanco_energia_subiste...	id_subistema fora do domínio {N, NE, S, SE, SIN} (detecta espaços em branco na sigla)	24096	ALERJA	Actuado real no arquivo de 2026 a sigla vem preenchida com espaços à direita ("N " em vez de "N") o que quebraria o join com dim_sa...
Consistencia	restricao_coff_eolica	id_estado fora do padrão de UF (2 letras maiúsculas) — indica deslocamento de coluna no C...	1810	ALERJA	Causa (no: aspas duplas não escapadas dentro de dtc_restricao quebram o parsing do CSV e deslocam os campos à direita. Na Silver ...
Consistencia	restricao_coff_fotovoltaica	id_estado fora do padrão de UF (2 letras maiúsculas)	420	ALERJA	Mesmo tratamento: quebramos em dtc_restricao_coff_rejeitados
Ordem	restricao_coff_eolica	geracao verificada acima de 1.5x a disponibilidade declarada	1870	ALERJA	Statuado, não impositivo pode ser reflexo de perda de atualização do cadastro de disponibilidade
Unicidade	restricao_coff_eolica	duplicatas na chave natural (id_pem, dtc_instalacao)	1788	ALERJA	Destinação por chave natural na Silver
Unicidade	restricao_coff_fotovoltaica	duplicatas na chave natural (id_pem, dtc_instalacao)	399	ALERJA	Destinação por chave natural na Silver
Acuracia	balanco_energia_subiste...	val_carga menor ou igual a zero	0	OK	Carga nula ou negativa em base horário seria erro: seria convertida para NULL
Acuracia	capacidade_geracon	potencia efetiva menor ou igual a zero	0	OK	Unidade geradora sem potência positiva é descartada do cálculo de capacidade instalada
Acuracia	est_detr_subistema	EAD verificada maior que a EAD maxima	0	OK	Armazenamento acima da capacidade máxima seria inconsistência de origem

23 rows 3.14% runtime

Figura 12 — As 23 regras de qualidade com contagem de violações, status e o tratamento adotado.

5.1 Problemas detectados e como tratei cada um

1) Colunas deslocadas no CSV de restrição — 2.230 linhas (1.810 eólica + 420 fotovoltaica). Detectei pela regra “id_estado fora do padrão de UF”. A causa raiz é aspas duplas não escapadas dentro do campo dsc_restricao, que quebram o parser de CSV e empurram todos os campos à direita. Como o deslocamento corrompe os valores numéricos da linha inteira, não dá para corrigir de forma confiável.

Tratamento: quarentena — essas linhas vão para silver.restricao_coff_rejeitados, com o motivo registrado, e não entram nos fatos. São 0,109% do total lido, volume que não altera nenhuma conclusão, e ficam preservadas para auditoria.

2) Sigla de subsistema com espaços à direita — 24.096 linhas. Achado real do arquivo de 2026: 'N ' em vez de 'N'. Passaria despercebido e quebraria

silenciosamente o join com `dim_subsistema`, jogando fora um ano inteiro de balanço. **Tratamento:** `trim()` em todas as colunas de identificação na Silver.

3) Nulos que não são falta de dado — ~60% das linhas de restrição.

`cod_razaorestricao` (806.904 + 484.380 linhas) e `val_geracaonaorealizadaapurada` (808.714 + 484.800 linhas) são nulos porque **naquele intervalo não houve restrição**. Tratar isso como “dado faltante” e imputar média seria um erro grave — inflaria o corte em mais de meio milhão de registros.

Tratamento: semântico, não estatístico — `corte_mwmed = 0.0`, `houve_restricao = false` e razão rotulada como 'Sem restricao'.

4) Duplicatas nas chaves naturais — 2.187 linhas. 1.788 na eólica e 399 na fotovoltaica, na chave (`id_ons`, `din_instante`). As demais quatro tabelas não apresentaram duplicata. **Tratamento:** `dropDuplicates` pela chave natural de cada tabela. Mantive a deduplicação no pipeline mesmo onde hoje o resultado é zero, porque o ONS reprocessa os arquivos mensalmente.

5) Linha agregada SIN misturada com os subsistemas. Não é erro do arquivo, é característica dele — mas somar tudo dobraria a energia. **Tratamento:** flag `eh_agregado` na Silver e exclusão explícita do SIN nos fatos por subsistema.

6) Violações de acurácia — 24 registros. 5 com geração verificada negativa, 4 com corte apurado maior que a geração de referência (impossível pela própria definição $GNRa = \text{referência} - \text{verificada}$) e 15 com `num_minutos_restricao` fora da faixa 0–30. Volume desprezível. **Tratamento:** os valores negativos viram NULL; os demais ficam sinalizados na tabela de qualidade. Essa última regra também serviu como **verificação de premissa:** ela confirma que o grão do arquivo é mesmo de 30 minutos, o que sustenta a conversão MWmed → MWh pelo fator 0,5 h.

7) Outliers — 1.870 registros com geração verificada acima de $1,5 \times$ a disponibilidade declarada. **Tratamento:** **sinalizei, não removi.** É provável defasagem entre a atualização do cadastro de disponibilidade e a medição. Removê-los enviesaria o denominador da taxa de corte para baixo, ou seja, inflaria artificialmente o indicador principal do trabalho. Preferi deixar o achado registrado e explícito.

8) Regras sem violação — 11 das 23. `val_carga` ausente, `val_carga` ≤ 0 , potência efetiva ≤ 0 , EAR verificada > EAR máxima, EAR percentual fora de 0–100, `din_instante` não conversível, código de razão fora do domínio, geração eólica horária acima do teto físico de 40 GWmed e duplicatas em três tabelas: todas com zero ocorrências. Mantive todas registradas com status OK — a ausência de problema também é resultado, e é o que evidencia que a verificação foi de fato executada e não apenas nas colunas onde eu já suspeitava de algo.

5.2 Efeito do tratamento: antes e depois

Fluxo	Bronze	Silver (válidos)	Silver (quarentena)	Gold (grão horário)
Restrição (eólica + fotovoltaica)	2.049.490	2.047.248	2.242	1.023.624

Nenhum registro “some” sem destino registrado: $2.049.490 = 2.047.248 + 2.242$. A redução de 2,05 M para 1,02 M na Gold não é perda — é a agregação intencional de dois intervalos de 30 minutos em uma hora.

6. Análise de Dados (Etapa 4.5)

Todas as consultas abaixo rodam sobre a camada Gold, em SQL e PySpark dentro do notebook 05_analise_perguntas, com os gráficos gerados por matplotlib no próprio Databricks.

P1 — Quanta energia foi cortada, e qual a taxa de corte?

```
SELECT coalesce(f.nom_fonte, 'TOTAL') AS fonte,
       round(sum(r.corte_mwh)/1000, 1)
AS corte_gwh,
       round(sum(r.geracao_mwh)/1000, 1)
AS geracao_verificada_gwh,
       round(sum(r.geracao_referencia_mwh)/1000, 1)
AS geracao_referencia_gwh,
       round(100*sum(r.corte_mwh)/sum(r.geracao_referencia_mwh), 2)
AS taxa_corte_pct
FROM mvp_ons.gold.fato_restricao_horaria r
JOIN mvp_ons.gold.dim_fonte_geracao f ON f.sk_fonte = r.sk_fonte
GROUP BY ROLLUP(f.nom_fonte) ORDER BY fonte
```

fonte	corte_gwh	geração verificada (GWh)	geração de referência (GWh)	taxa de corte
Eólica	13.157,2	53.328,0	68.222,0	19,29%
Fotovoltaica	6.914,8	18.163,0	24.890,9	27,78%
TOTAL	20.072,0	71.491,1	93.112,9	21,56%



Figura 13 — P1: volume cortado e taxa de corte por fonte.

Resposta. Entre 1º de março e 31 de agosto de 2026, as usinas eólicas e fotovoltaicas monitoradas pelo ONS deixaram de gerar **20.072 GWh (20,1 TWh)** por restrição de operação. A geração de referência — o que teriam produzido sem restrição — foi de 93.113 GWh, o que dá uma **taxa de corte de 21,6%**.

Para dar escala ao número: 20,1 TWh em seis meses é da ordem do consumo anual de um estado de porte médio. É energia já paga em CAPEX, com a turbina girando e o painel exposto ao sol, que simplesmente não vira eletricidade entregue.

P2 — Eólica e fotovoltaica são afetadas na mesma proporção?

fonte	usinas	corte (GWh)	taxa de corte	% do corte total
Eólica	153	13.157,2	19,29%	65,5%
Fotovoltaica	83	6.914,8	27,78%	34,5%

Resposta. Não. Em volume absoluto a eólica perde mais — 13.157 GWh contra 6.915 GWh da fotovoltaica — simplesmente porque há mais eólica instalada e ela gera 24 h por dia. Mas **em proporção a fotovoltaica é a mais penalizada: 27,8% de corte contra 19,3% da eólica.**

A explicação é de perfil de geração. A solar concentra toda a sua produção justamente nas horas em que o sistema já está saturado de renovável (meio do dia). A eólica, por gerar também à noite e de madrugada, tem horas “seguras” que diluem a sua taxa média. Para quem investe, isso é relevante: o risco de curtailment de um projeto solar novo no Nordeste é estruturalmente maior que o de um projeto eólico equivalente.

P3 — Qual a razão e a origem predominantes do corte?

WITH a AS (
 SELECT dsc_razao_restricao AS razao, dsc_origem_restricao AS origem,
 sum(corte_mwh) AS corte

```

FROM mvp_ons.gold.fato_restricao_horaria
WHERE houve_restricao_na_hora GROUP BY 1, 2)
SELECT razao, origem, round(corte/1000, 1) AS corte_gwh,
       round(100*corte/sum(corte) OVER (), 1) AS pct
FROM a ORDER BY corte DESC

```

razão	origem	% do corte
Razão energética (excesso de oferta)	Sistêmica	74,5%
Atendimento a requisitos de confiabilidade	Local	13,9%
Indisponibilidade externa (elétrica)	Sistêmica	7,0%
Indisponibilidade externa (elétrica)	Local	3,0%
Atendimento a requisitos de confiabilidade	Sistêmica	1,6%




Figura 14 — P3: distribuição do corte por razão e origem.

Resposta. O corte é dominado por **razão energética de origem sistêmica: 74,5% de todo o volume cortado**. Razão energética, no dicionário do ONS, significa controle de frequência do SIN — em português claro, *sobra de geração*. Os outros 25,5% se dividem entre confiabilidade local (13,9%), indisponibilidade externa sistêmica (7,0%), indisponibilidade externa local (3,0%) e confiabilidade sistêmica (1,6%).

Essa é a descoberta mais importante do trabalho, porque muda o diagnóstico. A narrativa comum é que “falta linha de transmissão”. Os dados dizem que **três quartos do desperdício não são gargalo de rede: é energia que não tem para onde ir em nenhum lugar do sistema naquela hora**. Construir mais transmissão resolve o quarto restante. Resolver os três quartos exige deslocar consumo no tempo —

armazenamento, resposta da demanda, hidrogênio, ou carga nova posicionada no horário certo.

P4 — Como o corte evoluiu mês a mês?



Figura 15 — P4: energia cortada por mês (barras) e taxa de corte (linha).

Resposta. O corte mais do que triplicou dentro da própria janela: de **1.706 GWh em março para 5.615 GWh em agosto**. A taxa subiu de **15,4% para 27,8%** — ou seja, no fim do período mais de um quarto de toda a energia renovável disponível estava sendo jogada fora.

Parte disso é sazonal (o segundo semestre é a estação de ventos fortes no Nordeste, e a carga do inverno é menor), mas a inclinação é forte demais para ser só sazonalidade. A fatia de razão energética oscila entre 66% e 85% sem tendência clara de queda, o que indica que o problema estrutural não está sendo aliviado.

P5 — Qual subsistema concentra o corte?

subsistema	% do corte total	corte (GWh)
Nordeste	81,1%	16.286
Sudeste/Centro-Oeste	15,9%	3.187 (dos quais 3.144 fotovoltaicos)
Sul + Norte	< 3%	—

E a explicação aparece na consulta de contexto, que é o achado mais eloquente do trabalho:

subsistema	penetração intermitente / carga	% de horas com carga líquida negativa
Nordeste	113,3%	69,1%
Demais subsistemas	9% a 13%	~0%




Figura 16 — P5: concentração do corte por subsistema e penetração de geração intermitente.

Resposta. O Nordeste responde por 81,1% de todo o corte (16.286 GWh), seguido do Sudeste/Centro-Oeste com 15,9% — este quase inteiramente fotovoltaico. Sul e Norte somam menos de 3%.

No período, a geração eólica e solar do Nordeste equivaleu a **113,3% da carga do próprio subsistema**, e em **69,1% das horas a geração intermitente sozinha superou toda a demanda local**. Nos demais subsistemas a penetração fica entre 9% e 13% e as horas de carga líquida negativa são praticamente zero.

Ou seja: o Nordeste virou um exportador estrutural de energia que depende inteiramente da capacidade de escoamento para o resto do país. Quando essa capacidade se esgota — e ela se esgota em dois terços das horas — a única saída do operador é cortar. O corte não acompanha a penetração de forma linear: ele explode a partir do ponto em que a geração local passa a superar a carga local.

P6 — Existe padrão horário? Eólica e solar são cortadas nos mesmos horários?




Figura 17 — P6: energia cortada por hora do dia, eólica vs. fotovoltaica.

hora	corte eólica (GWh)	taxa eólica	corte solar (GWh)	taxa solar
4h	213,2	6,7%	0	—
10h	1.406,2	50,9%	1.081,4	38,7%
12h	1.255,3	55,0%	1.033,8	37,6%
18h	117,9	4,6%	0	—

Resposta. Sim, e o padrão é inequívoco. O corte se concentra entre **8h e 15h, com pico às 10h–12h**. Nesse pico, a eólica chega a perder **55% de toda a energia que poderia gerar** e a fotovoltaica cerca de 38%. Fora da janela solar (18h às 6h) a taxa de corte da eólica cai para a faixa de 6% a 9%.

É a curva do pato brasileira. O que o gráfico mostra é que **a eólica está sendo cortada pela solar**: nas horas de sol, as duas fontes competem pelo mesmo espaço em um sistema que já está cheio, e a eólica — que naquele momento tem vento disponível — é desligada junto. Isso tem consequência direta de negócio: usinas eólicas no Nordeste estão sendo penalizadas por um excedente que não é delas, e qualquer solução de armazenamento posicionada nessa janela de quatro a seis horas ataca a maior parte do problema.

P7 — O corte está concentrado em poucas usinas ou é difuso?

% das usinas (ordenadas por corte)	% do corte acumulado
10%	32,6%
20%	51,2%
30%	64,5%
50%	81,5%
75%	94,6%

Resposta. O corte é **difuso, não concentrado**. As 10 usinas mais afetadas somam apenas 16,9% do total; os 20% maiores respondem por 51,2%; metade das usinas responde por 81,5%. Nenhuma usina isolada passa de 2,4% do corte total.

Essa distribuição confirma o resultado de P3 por outro caminho. Se o problema fosse gargalo de rede, ele apareceria concentrado nas usinas penduradas em poucas subestações críticas. Como o corte é sistêmico e atinge quase todo mundo mais ou menos na mesma proporção, **não existe uma obra pontual que resolva** — o que existe é um desequilíbrio de oferta e demanda que atinge todo o parque simultaneamente.




Figura 18 — P7: as 15 usinas com maior corte e a curva de concentração (Pareto).

P8 — O corte energético ocorre nas horas de menor carga líquida e com reservatórios mais cheios?

quintil de carga líquida do SIN	corte (GWh)	% do corte total	% por razão energética
1 (menor carga líquida)	12.117,1	60%	93,3%
2	3.814,8	—	—
3	2.232,6	—	—
4	1.274,5	—	—
5 (maior carga líquida)	633	—	9,9%

Correlação diária no Nordeste (184 dias): corte × carga líquida do SIN = **−0,666**; corte × EAR do Nordeste = **−0,198** (EAR variando entre 73,2% e 96,5%).

P8. O corte energético acompanha a carga líquida e o nível dos reservatórios?




Figura 19 — P8: corte por quintil de carga líquida e correlações diárias.

Resposta — parte da carga líquida: confirmada, e com força. Dividindo todas as horas do período em cinco faixas de carga líquida do SIN, o quintil de **menor** carga líquida concentra **12.117 GWh — 60% de todo o corte do semestre** — e nele **93,3% do corte é por razão energética**. No quintil de maior carga líquida o corte cai para 633 GWh e apenas 9,9% dele é energético (o resto é rede). O gradiente é monotônico nos cinco quintis. A correlação diária entre corte no Nordeste e carga líquida do SIN é de **-0,666**.

Isso fecha o argumento: o curtailment brasileiro é, em três quartos, um problema de **excesso de oferta em hora de demanda baixa** — exatamente o que um sistema de armazenamento existe para resolver.

Parte dos reservatórios: não confirmada. A correlação entre corte no Nordeste e nível de armazenamento do subsistema é de apenas **-0,198**, fraca. O motivo fica claro olhando a faixa de variação: a EAR do Nordeste ficou entre 73,2% e 96,5% o tempo todo, quase sempre na faixa “Alto”. Com tão pouca variação, a janela de seis meses não permite separar o efeito do reservatório do efeito da carga líquida. **Deixo registrado como pergunta parcialmente respondida** — precisaria de uma série de vários anos, cobrindo períodos de escassez hídrica, para testar de verdade.

P9 — Como evoluiu a penetração de eólica e solar entre 2021 e 2026?

ano	penetração intermitente / carga	pico horário	horas-subsistema com carga líquida negativa
2021	13,3%	142,0%	1.025
2022	15,5%	196,1%	—
2023	21,4%	195,8%	—
2024	26,1%	184,6%	—
2025	29,7%	192,7%	6.310
2026 (parcial)	28,7%	—	—

P9. Como evoluiu a penetração de eólica e solar entre 2021 e 2026?




Figura 20 — P9: penetração de geração intermitente sobre a carga do SIN, 2021–2026.

Resposta. A penetração de eólica e solar sobre a carga do SIN saiu de **13,3% em 2021 para 29,7% em 2025** — mais que dobrou em quatro anos. O número de horas-subsistema com carga líquida negativa (geração intermitente sozinha maior que toda a demanda local) foi de **1.025 em 2021 para 6.310 em 2025**, um crescimento de mais de seis vezes. 2026 aparece com 28,7% porque o arquivo do ano está incompleto (vai até setembro) e os meses que faltam são de vento forte.

Essa curva é a causa do problema medido nas oito perguntas anteriores. O parque renovável cresceu muito mais rápido do que a capacidade do sistema de absorvê-lo, e o constrained-off é o mecanismo pelo qual o operador fecha essa conta todo dia.

Discussão geral

Amarrando as nove respostas ao problema original:

Em seis meses de 2026 o SIN desperdiçou **20,1 TWh** de energia eólica e fotovoltaica — **21,6%** de tudo o que essas usinas poderiam ter gerado — e a taxa estava em trajetória de alta, fechando agosto em 27,8%. O desperdício tem endereço: **81% dele acontece no Nordeste**, subsistema em que a geração intermitente equivaleu a 113% da carga local e superou sozinha toda a demanda em 69% das horas do período.

A causa não é a que se costuma citar. **Três quartos do corte são por razão energética sistêmica**, não por gargalo de transmissão — é energia sem destino no sistema inteiro naquela hora. Três evidências independentes convergem para isso: a classificação do próprio ONS (74,5% ENE/sistêmica), a distribuição difusa entre usinas (metade do parque responde por 81% do corte, nenhuma usina passa de 2,4%) e o gradiente de carga líquida (60% do corte no quintil de menor carga líquida, com 93% dele de razão energética).

O corte também tem hora marcada: **8h às 15h, pico às 10h–12h**, quando a eólica chega a perder 55% do seu potencial. A solar, que só existe nessa janela, é proporcionalmente a mais penalizada (27,8% contra 19,3% da eólica).

A leitura de negócio que decorre disso é direta. Reforço de transmissão endereça o quarto do problema que é de rede. Os outros três quartos são um problema de **deslocamento temporal**: armazenamento com quatro a seis horas de duração posicionado no Nordeste, resposta de demanda, ou carga nova (data center, hidrogênio, dessalinização) que consuma justamente na janela 8h–15h. E, no limite, qualquer projeto renovável novo no Nordeste precisa ser avaliado com uma premissa de curtailment de dois dígitos no fluxo de caixa — o que, pelos dados deste semestre, já é o cenário-base, não o pessimista.

Das nove perguntas, oito foram respondidas integralmente. A P8 ficou parcial: a relação entre corte e nível de reservatório não pôde ser testada porque a EAR do Nordeste variou pouco (73%–96%) na janela de seis meses.

7. Autoavaliação

Consegui atingir o objetivo?

Sim, na essência. O objetivo que tracei antes de começar era dimensionar o desperdício de geração renovável por constrained-off, identificar a causa dominante e localizar onde ele se concentra — e o pipeline entrega as três coisas com número, fonte rastreável e consulta reproduzível. Saí de cinco arquivos CSV crus para um modelo dimensional que responde a nove perguntas de negócio, tudo dentro de um ambiente de nuvem, sem nada rodando na minha máquina.

Oito das nove perguntas foram respondidas integralmente. A P8 ficou parcialmente respondida e manteve a pergunta original intacta, como manda o enunciado: a parte da carga líquida foi confirmada com força (correlação $-0,666$, gradiente monotônico em cinco quintis), mas a parte dos reservatórios não. A razão é honesta e conhecida: escolhi uma janela de seis meses para os dados de restrição, e nessa janela a EAR do Nordeste variou apenas entre 73% e 96%, quase sempre na faixa “Alto”. Sem variação na variável explicativa, não há como testar a hipótese — o resultado ($-0,198$) não diz que a relação não existe, diz que os dados que coletei não conseguem enxergá-la. Isso é uma limitação de desenho de coleta, e é exatamente o tipo de coisa que um Engenheiro de Dados precisa saber reconhecer antes que vire uma conclusão errada em um relatório.

O que foi mais difícil

A qualidade dos dados de origem, de longe. Eu esperava CSVs bem comportados de um órgão oficial e encontrei três armadilhas que só apareceram porque eu profilei antes de transformar:

1. **As aspas duplas não escapadas** dentro de `dsc_restricao`, que deslocam colunas inteiras no parsing. Esse foi o mais difícil de diagnosticar: o sintoma aparece numa coluna (`id_estado` com valor estranho) muito distante da causa (um campo de texto livre três colunas antes). Cheguei nele escrevendo uma regra de domínio para UF e olhando as linhas que ela pegou.
2. **A sigla 'N' com espaço à direita** no arquivo de 2026. Um `trim()` esquecido teria feito um ano inteiro de balanço desaparecer silenciosamente no join, sem erro, sem aviso — só um número menor do que deveria.
3. **Os 60% de nulos que não eram falta de dado.** Foi a decisão mais importante do trabalho, e é semântica, não técnica: qualquer rotina automática de imputação teria inflado o corte em mais de meio milhão de registros. Para acertar isso eu tive que ler o dicionário de dados oficial do ONS, não apenas olhar o arquivo.

O join sem chave comum entre restrição e cadastro de capacidade também deu trabalho. As duas fontes do ONS não compartilham identificador utilizável (o `ceg` está ausente em $\sim 93\%$ das linhas de restrição), e a saída foi normalizar o nome da usina. Funciona, mas é frágil por natureza — por isso criei a flag `tem_cadastro_capacidade`, para que o modelo nunca finja que um match ausente é potência zero.

A restrição de recursos da Free Edition me obrigou a decidir escopo em vez de processar tudo. Os arquivos mensais de restrição têm ~ 40 MB cada com granularidade de 30 minutos por usina; pegar a série completa estouraria o tempo de execução disponível. Optar por seis meses (2 M de registros) foi uma escolha deliberada de MVP — e é a mesma escolha que limitou a P8.

O que eu faria diferente

- **Ingestão incremental em vez de overwrite.** Hoje todo o pipeline reescreve as tabelas. Funciona para um MVP, mas o certo seria MERGE com Delta, gravando só o que mudou.
- **Agendar como Job.** O pipeline está pronto para isso (notebooks parametrizados, idempotentes, encadeados), mas eu executei manualmente.
- **Testes automatizados de contrato.** As regras de qualidade hoje registram violações; elas não interrompem o pipeline. Para produção, algumas deveriam falhar a execução.

Trabalhos futuros

1. **Estender a janela de restrição para a série completa (2021–2026)** para responder a P8 de verdade, cobrindo períodos de escassez hídrica em que a EAR realmente varia.
2. **Cruzar com o preço (PLD horário)** para converter os 20,1 TWh em valor financeiro e estimar a perda de receita por usina — é o número que efetivamente destrava uma conversa de investimento.
3. **Modelar o benefício de armazenamento:** simular quanto do corte das 8h–15h uma bateria de 4 h de duração recuperaria, por subsistema, e qual o payback implícito.
4. **Cruzar com o mapa de subestações e capacidade de escoamento** para separar com precisão o quarto do corte que é rede do restante que é oferta.
5. **Dashboard no Databricks SQL** com a taxa de corte por usina atualizada mensalmente, e alerta quando alguma usina ultrapassar um limiar.
6. **Publicar o modelo como produto de dados** com Genie/Unity Catalog, permitindo que a área de negócio pergunte em linguagem natural sobre o parque.

Como peça de portfólio, o que eu levo deste MVP não é o Databricks em si — é o raciocínio de ponta a ponta: partir de uma pergunta de negócio, escolher a fonte pela pergunta, desconfiar do dado antes de transformá-lo, documentar cada decisão no catálogo e só então concluir. E, principalmente, saber dizer com clareza qual pergunta os dados que eu coletei **não** conseguem responder.
